keepcoding

KEEPCODING · AI ENGINEERING · PROYECTO FINAL

Company Brain

Un asistente de IA que conoce los documentos de la consultora y responde en segundos, sin que ningún dato salga del portátil

Ángeles Hernández Acosta · 7 de noviembre de 2026



EL PROBLEMA

Las consultoras pierden horas buscando información que ya tienen

Hoy

- La información está repartida en llamadas, propuestas, contratos e informes
- Encontrar “¿qué acordamos con este cliente?” puede llevar horas
- Es confidencial: no se puede subir a ChatGPT ni a la nube

Con Company Brain

Pregunta y obtén la respuesta con su fuente

Resume una llamada de una hora en minutos

Redacta propuestas con tu método de trabajo



keep coding

LAS REGLAS DEL PROYECTO

Diseñado para una empresa pequeña

0 €

de coste mensual: sin nube ni suscripciones

16 GB

un portátil normal (MacBook Air), sin servidores

2

idiomas: inglés y español

77

documentos de prueba, inventados o públicos

Todavía no incluye: datos reales de clientes ni “entrenar” la IA a medida. Vendrá después.

Técnico: todo local y de código abierto: Ollama · PostgreSQL 18 + pgvector · Docling · Open WebUI · cortafuegos LuLu · servicios launchd (macOS) · MacBook Air M4 de 16 GB. Corpus: 60 documentos ficticios propios + 17 públicos con licencia comercial (CUAD, CORD, informes de la UK Statistics Authority y del Ararteko).



keepcoding

CONFIANZA Y ÉTICA

Condiciones que el sistema cumple siempre

Privacidad

Nada sale del portátil. La IA no accede a internet y las copias de seguridad van cifradas.

Datos de prueba seguros

Probado solo con documentos inventados o públicos, con permiso para uso comercial.

Respeto a la autoría

No usa libros ni obras protegidas. Las propuestas siguen mi propio método de trabajo.

Honestidad

Cada respuesta dice de dónde sale. Si no lo sabe, lo dice, y no obedece órdenes escondidas en los documentos.

Técnico: privacidad: LuLu bloquea internet a cada proceso de la IA (lo comprueba "Check health"); copias cifradas con age y firmadas. Honestidad: guardarraíl de salida con HHEM-2.1 (puntúa cada afirmación frente a su fuente), umbral de relevancia por idioma que devuelve "no lo sé" y aislamiento por cliente. Seguridad: auditoría OWASP Top 10:2025 y OWASP Top 10 para aplicaciones LLM 2025.

EL CEREBRO DEL SISTEMA

Elegimos el modelo de IA que cabe en un portátil

Modelo de IA (gratuito y abierto)	¿Cabe en el portátil?	Decisión
Gemma 4 12B (grande)	No: lo bloquea	Descartado
Qwen 3.5 9B (mediano)	No: lo bloquea	Descartado
Qwen 3.5 4B (pequeño)	Sí, y funciona con fluidez	Elegido

8 s

para responder una pregunta

45 s

para redactar una propuesta

3 min

para resumir una llamada de 1 h

Técnico: Qwen3.5-4B (cuantización NVFP4) en Ollama, contexto de 16k tokens, temperatura 0,2. Criterio: ≤ 14 GB de memoria y sin presión crítica con los modelos de búsqueda cargados (benchmark propio con vm_stat y memory_pressure). Tiempos: mediana en caliente.

CÓMO APRENDE LO DE LA EMPRESA

Consulta los documentos en vez de memorizarlos

HECHO

Instrucciones claras

Tres tareas (responder, resumir, redactar) con reglas: citar siempre la fuente y seguir mi método.

HECHO · LA CLAVE

Búsqueda (RAG)

Antes de responder, busca los párrafos útiles en los documentos. Un documento nuevo sirve al momento, sin reentrenar.

MÁS ADELANTE

Entrenamiento

Con pocos documentos propios, entrenar la IA costaría mucho y aportaría poco. Lo probaremos con más datos.

Técnico: prompt engineering con 3 modos (responder, resumir, redactar), citas [n] obligatorias y respuesta en el idioma de la pregunta. RAG híbrido: pgvector (EmbeddingGemma 2) + búsqueda de texto completo de PostgreSQL en ES y EN, fusión RRF (k = 60), 20 candidatos → reranker cross-encoder (mMiniLM) → 5 pasajes. Fine-tuning (QLoRA con Unsloth o MLX) aplazado: menos de 50 documentos propios y 16 GB.

CÓMO FUNCIONA

De un documento en Drive a una respuesta con

1 · CUANDO LLEGA UN DOCUMENTO NUEVO

Google Drive la carpeta de la empresa → **Lectura** PDF, Word y fotos (Docling) → **Fragmentos** indexados por significado (EmbeddingGemma 2) → **Archivo** base de datos local (PostgreSQL con pgvector)

2 · CUANDO HACES UNA PREGUNTA

Búsqueda por sentido y por palabras (método RRF) → **Filtro** elige los mejores pasajes (mMiniLM) → **Redacción** la IA responde con ellos (Qwen 3.5 4B) → **Respuesta** con fuentes [1] [2]

Arquitectura RAG completa, comparada antes de elegir: probamos 3 modelos que convierten el texto en «significado» (Qwen3-Embedding 0.6B, bge-m3 y EmbeddingGemma 2). Misma calidad; EmbeddingGemma 2 fue el más rápido.

keepcoding

LISTO PARA USAR

Un producto que se usa con un doble clic

FASE · INTEGRACIÓN

Fácil de usar

Ventana de chat como la de ChatGPT (Open WebUI), conectada a nuestra propia API local mediante una Pipe. Descarga en Word y PDF.

FASE · MLOPS (DESPLIEGUE)

Funciona solo

Despliegue automático: se enciende y se apaga con un botón; otro comprueba que todo está bien.

FASE · MLOPS (SEGURIDAD)

Seguro

Copia de seguridad cifrada y firmada cada noche y revisión de seguridad superada (auditoría OWASP).

Optimizado para 16 GB: cada pieza se carga solo cuando hace falta, para que el portátil no se bloquee.

Técnico: 4 servicios launchd (PostgreSQL, Ollama, API propia en 127.0.0.1:8765, Open WebUI) · script brainctl (start, stop, health, update, backup) · modelos cargados bajo demanda.

keep coding

¿FUNCIONA DE VERDAD?

Lo pusimos a prueba con 66 preguntas, en inglés español

Qué le preguntamos

- Datos concretos: tarifas, fechas, acuerdos
- Resúmenes de llamadas
- Preguntas sin respuesta: debe decir “no lo sé”
- Documentos con trampas para engañarle

Cómo lo comprobamos

- ¿Encuentra el documento correcto? (recall@5 y MRR)
- ¿El dato es exacto y cita su fuente?
- Otra IA más grande corrige las respuestas (Gemma 4 12B)
- Yo valoro 20 respuestas sin saber cuál es cuál

22 preguntas se guardaron en secreto hasta la prueba final, como un examen que nadie ha visto antes.
Panel de resultados propio y sin conexión (en lugar de Weights & Biases): ningún dato sale del portátil.

Técnico: métricas propias (recall@5, MRR, dato exacto, citas, rechazo) + Ragas (fidelidad y relevancia) con Gemma 4 12B como juez + HHEM. Examen: 22 preguntas cifradas con age, ejecutadas una sola vez con la configuración congelada (config/selected.toml).



keep coding

RESULTADOS

Encuentra la fuente y no inventa cifras

16/22
preguntas superadas (73 %)

94 %
encuentra el documento correcto

22/22
respuestas sin cifras inventadas

0,80
sobre 1: fidelidad a las fuentes

Qué falta mejorar

Relevancia 0,70 sobre 1: a veces responde de más. Y cayó en las 2 trampas del examen.
Dijo “no lo sé” 2 de 3 veces · En la práctica (44 preguntas): 41/44

Técnico: MRR 0,94 · fidelidad 0,80 (objetivo 0,90) · relevancia 0,70 (objetivo 0,80) · rechazo 2/3 (objetivo 90 %) · 0 bloqueos graves · estado “pilot, below target”. Informe con huellas SHA-256 en reports/final_eval.md.



keep coding

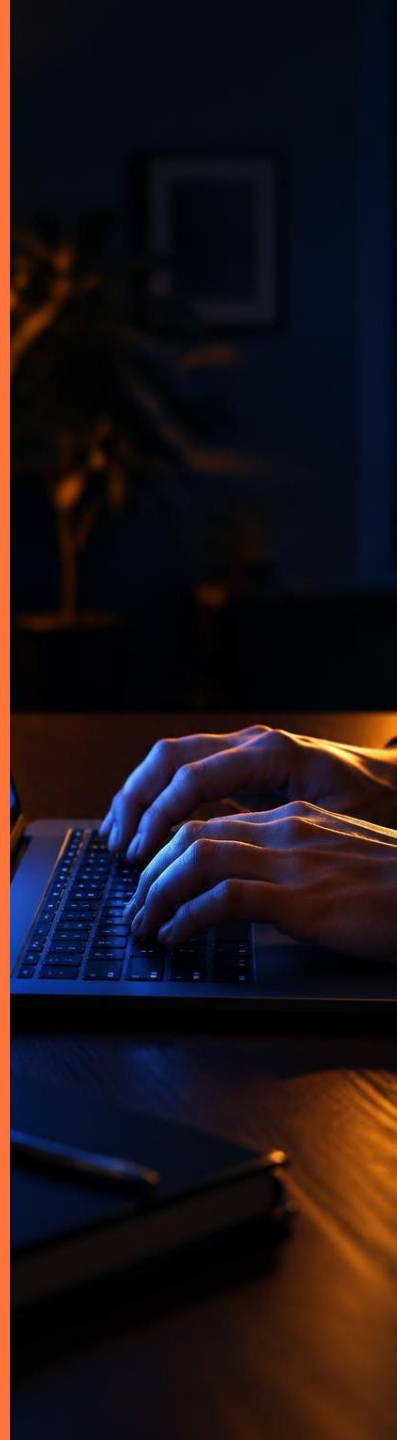
DEMOSTRACIÓN · 4 MINUTOS

Veámoslo funcionar

1. Una pregunta: “¿Qué tarifa acordamos con Pellmore Dental Group?”, con su fuente
2. Una pregunta sin respuesta: dice que no lo encuentra
3. Una propuesta redactada con mi método, descargada en PDF

Cliente inventado · la IA funciona sin internet

Técnico: Open WebUI → Pipe → API local (127.0.0.1:8765) → búsqueda híbrida → reranker → Qwen3.5-4B → respuesta con fuentes.



keep coding

CONCLUSIONES

Una IA privada y útil, en un portátil y sin coste mensual

Lo que he aprendido

- No hace falta la IA más grande: basta una pequeña bien informada
- Con pocos documentos, buscar es mejor que entrenar
- Que la IA diga “no lo sé” vale más que una respuesta inventada
- Sin pruebas propias, no se puede saber si mejora

Lo que molesta

- El cortafuegos avisa a menudo, también con la IA apagada
- Hay que elegir el modo y el cliente en cada chat
- Es el precio de la privacidad y de no mezclar clientes

Próximos pasos

- Usarlo con clientes reales
- Más defensas contra trampas y probar el entrenamiento a medida
- Grafo de conocimiento: clientes, proyectos y personas
- Cortafuegos más discreto: bloquear solo a la IA
- Que sugiera el modo y el cliente, y tú confirmes

Técnico: próximos pasos: fine-tuning QLoRA (Unsloth o MLX-LM) medido con un examen bloqueado nuevo; grafo de conocimiento sobre PostgreSQL; defensas contra prompt injection (separar instrucciones y datos, detectar órdenes en los documentos); recalibrar el umbral de relevancia en inglés. LuLu filtra todo el Mac → modo pasivo con reglas de bloqueo solo para los procesos de la IA. Un cliente por chat es intencionado (aislamiento); el modo podría elegirlo un enrutador de intención con confirmación.

keep coding

COMPANY BRAIN

Gracias.
¿Preguntas?

Código: github.com/angelescacosta/company-brain

Datos de prueba: huggingface.co/datasets/AHAcosta/company-brain-eva

